

Απαλλακτική εργασία εξαμήνου (έως 3 άτομα ανά ομάδα)

Το σύνολο των δεδομένων προέρχεται από μια πλατφόρμα ανίχνευσης χημικών ουσιών σε εργαστηριακή κλίμακα, η οποία περιλαμβάνει αισθητήρες αερίων οξειδίου του μετάλλου (metal oxide - MOX). Οι λεπτομέρειες του dataset περιγράφονται στη σχετική σελίδα του UCI Machine Learning Repository¹, απ' όπου και θα το κατεβάσετε.

Η εργασία χωρίζεται σε τέσσερις κύριες ενότητες που αξιολογούν την ικανότητα προ-επεξεργασίας ροών αισθητήρων μεγάλης κλίμακας, σχεδιασμού περιγραφικών δεικτών, διεξαγωγής αυστηρών χρονικών διαγνωστικών και δημιουργίας ανταγωνιστικών αγωγών πρόβλεψης, αντίστοιχα.

1. PREPROCESSING AND DATA UNDERSTANDING (30 %)

Κατεβάστε τα δεδομένα και διαβάστε τα αρχεία με χρήση Apache Spark. Λόγω του ρυθμού δειγματοληψίας που εφαρμόστηκε στα πειράματα, θα χρειαστεί να κανονικοποιήσετε τη στήλη timestamp. Για να υπάρχει μια κοινή βάση, δημιουργήστε μέσω της μεθόδου `date_range` που παρέχει το `pyspark` μια χρονική ακολουθία με αρχή 2025-09-01 και ρυθμό 5 λεπτά **για κάθε αισθητήρα** (group per sensor, use `periods = len_of_timeseries`).

Στη συνέχεια προβείτε στις απαραίτητες ενέργειες preprocessing (π.χ., εντοπίστε τις ελλείπουσες τιμές, τις ακραίες τιμές) και αντιμετωπίστε οποιεσδήποτε ανωμαλίες κρίνετε σκόπιμο. Καταγράψτε τις επιλογές που κάνετε. Συνοδεύστε τα βήματα που εκτελέσατε και τα συμπεράσματα που αντλήσατε με αντίστοιχες οπτικοποιήσεις. Δημιουργήστε διαγράμματα κουτιού, ιστογράμματα και καμπύλες πυκνότητας (ή οποιεσδήποτε άλλες οπτικοποιήσεις θεωρείτε ενημερωτικές) που εκθέτουν τις ιδιότητες κατανομής των βασικών μεταβλητών (π.χ. τάσεις αισθητήρων, τάση θερμοαντήρα, συγκέντρωση CO, υγρασία). Αποθηκεύστε τα σχήματα για αναφορά.

Στη συνέχεια, με PySpark εκτελέστε τα εξής:

- Επιλέξτε όλες τις εγγραφές με τάση μεγαλύτερη από το 60% της μέγιστης και υπολογίστε τη συνολική συγκέντρωση (CO).
- Ομαδοποιήστε τα δεδομένα ανά αναγνωριστικό αισθητήρα και υπολογίστε τόσο τη μέση τιμή όσο και τη διακύμανση της αντίστασης τους.
- Χρησιμοποιήστε έναν accumulator που αυξάνεται κάθε φορά που η συγκέντρωση (CO (ppm)) είναι αυστηρά μεγαλύτερη από 10 ppm και η σχετική υγρασία είναι αυστηρά χαμηλότερη από 30 % RH και εξάγετε την τελική τιμή του.
- Δημιουργήστε μια νέα στήλη **R** που υπολογίζει **εκ νέου** την αντίσταση μέσω της τάσης χρησιμοποιώντας τον ακόλουθο τύπο
$$R = \frac{5-V}{V} \times 1.000.000$$
. Στη συνέχεια εκτελέστε μια μείωση βάσει κλειδιού που επιστρέφει, για κάθε τιμή της τάσης θερμοαντήρα, τη μέγιστη υπολογισμένη αντίσταση **R**. Παρουσιάστε το αποτέλεσμα ως πίνακα δύο στηλών.

¹ <https://archive.ics.uci.edu/dataset/487/gas+sensor+array+temperature+modulation>

- (v) Φιλτράρετε το σύνολο δεδομένων για ένα συγκεκριμένο αισθητήρα, ορίστε ένα παράθυρο 25 λεπτών και υπολογίστε τη μέση συγκέντρωση CO και τη μέση υγρασία σε κάθε παράθυρο.

2. FEATURE ENGINEERING (20 %)

Σε αυτό το στάδιο, τα καθαρισμένα δεδομένα μεταφέρονται σε ένα περιβάλλον pandas. Δημιουργήστε τουλάχιστον 3 νέα contextual χαρακτηριστικά (features) που εμπλουτίζουν τις αρχικές μετρήσεις. Σκοπός είναι να ανακαλύψετε νέους τρόπους αλληλεπίδρασης των χαρακτηριστικών προκειμένου να τα χρησιμοποιήσετε για τις προβλέψεις σας. Προτεινόμενα παραδείγματα είναι τα εξής:

- Διαφορά θερμοκρασίας μεταξύ διαδοχικών χρονικών στιγμών,
- Κατηγορική ετικέτα που προσδιορίζει την τρέχουσα φάση του θερμαντήρα (χαμηλή ή υψηλή τάση)
- Μέσος όρος των 14 αντιστάσεων του αισθητήρα

Απεικονίστε επίσης τη σχέση μεταξύ του μ.ό. των αισθητήρων και ενός κυλιόμενου μ.ό.. 25 λεπτών (5 εγγραφές) της συγκέντρωσης CO σε ένα τυχαία επιλεγμένο διάστημα ή κατά μήκος όλου του διαστήματος.

3. TEMPORAL ANALYSIS (15 %)

Σε αυτή την ενότητα, θα πραγματοποιήσετε μια διεξοδική διαγνωστική έρευνα. Ο στόχος είναι να αποκαλυφθεί η υποκείμενη δυναμική των αισθητήρων και να ποσοτικοποιηθούν οι χρονικές εξαρτήσεις. Κάθε ερώτημα απαιτεί ένα ποσοτικό αποτέλεσμα και μια οπτική αναπαράσταση.

Πρώτα, εφαρμόστε seasonal decomposition στη χρονοσειρά που αντιπροσωπεύει τον μ.ο. των 14 αντιστάσεων των αισθητήρων. Σχεδιάστε κάθε συνιστώσα στο δικό της υποδιάγραμμα, διατηρώντας τον αρχικό άξονα χρόνου, έτσι ώστε να παρατηρήσετε πώς εξελίσσονται η μακροπρόθεσμη μετατόπιση (trend), η περιοδική επίδραση του θερμαντήρα και οι ανεξήγητες διακυμάνσεις. Σε μια σύντομη περιγραφή, εξηγήστε τυχόν συστηματικά μοτίβα που παρατηρήθηκαν, όπως για παράδειγμα αν η τάση παρουσιάζει μια αργή ανοδική μετατόπιση που υποδηλώνει γήρανση του αισθητήρα.

Στη συνέχεια, εστιάστε στην υπολειπόμενη συνιστώσα που προέκυψε από το βήμα STL. Υπολογίστε τη συνάρτηση αυτοσυσχέτισης (ACF) και τη συνάρτηση μερικής αυτοσυσχέτισης (PACF). Δημιουργήστε δύο ξεχωριστά γραφήματα γραμμών που εμφανίζουν τις τιμές συσχέτισης μαζί με τα διαστήματα εμπιστοσύνης 95% που εμφανίζονται συνήθως στα εγχειρίδια χρονοσειρών. Προσδιορίστε τις καθυστερήσεις που υπερβαίνουν το διάστημα εμπιστοσύνης και σημειώστε τις σε μια σύντομη παράγραφο. Αυτές οι καθυστερήσεις υποδηλώνουν το μήκος μνήμης του συστήματος και θα είναι χρήσιμες κατά την επιλογή των σειρών μοντέλων για μετέπειτα προβλέψεις.

Τέλος, ελέγξτε τη στασιμότητα των υπολειμμάτων εκτελώντας ένα στατιστικό τεστ. Καταγράψτε το στατιστικό της δοκιμής την αντίστοιχη τιμή p και συνοψίστε το αποτέλεσμα σε μια συνοπτική δήλωση. Σημειώστε την παρουσία ενός unit root και να συζητήσετε πιθανές λύσεις που θα μπορούσαν να εφαρμοστούν πριν από την κατασκευή προγνωστικών μοντέλων.

4. MACHINE LEARNING MODEL TRAINING (35 %)

Σκοπός του συγκεκριμένου ερωτήματος είναι η βραχυπρόθεσμη πρόβλεψη της αντίστασης (R) **ανά αισθητήρα** στα επόμενα 5 λεπτά (1-step forecast). Χωρίστε το σύνολο δεδομένων σε 3 (υπο)σύνολα, εκπαίδευσης, επικύρωσης και δοκιμής, με αναλογία 70-20-10. Εκπαιδεύστε ένα μοντέλο μηχανικής μάθησης (ενδεικτικά, μπορείτε να επιλέξετε μεταξύ Decision Trees, Linear Regression, Random Forests, κ.α.) χρησιμοποιώντας τη βιβλιοθήκη MLlib του Spark. Δημιουργήστε ένα pipeline που εκτελεί την κανονικοποίηση, τη δημιουργία των διανυσμάτων χαρακτηριστικών και την πρόγνωση του μοντέλου και αξιολογήστε την απόδοσή του. Παρόμοια, κατασκευάστε μια αρχιτεκτονική που βασίζεται στα αναδρομικά νευρωνικά δίκτυα (RNN / LSTM / GRU) και εκτελέστε την ίδια διαδικασία (διαχωρισμός δεδομένων, εκπαίδευση, αξιολόγηση).

Αξιολογήστε την επίδοση των μοντέλων σας χρησιμοποιώντας τις μετρικές σφάλματος MAE, MAPE, RMSE και R^2 και υπολογίστε τους χρόνους εκπαίδευσης (train) και πρόβλεψης (inference) ώστε να κάνετε μια πιο ολοκληρωμένη σύγκριση. Παρουσιάστε τα αποτελέσματα σε μορφή πίνακα όπου σαν δείκτης θα αναγράφονται τα αναγνωριστικά των αισθητήρων, και στις στήλες θα αναγράφονται οι σχετικές τιμές των 4 μετρικών.

Σημείωση: επειδή η πρόβλεψη θα γίνεται ανά αισθητήρα, το οποίο σημαίνει ότι για ένα συγκεκριμένο χρονικό ορίζοντα και μία μετρική δεν έχουμε 1 αλλά 14 τιμές, στον πίνακα να αναγράφεται η μέση τιμή και η τυπική απόκλιση του σφάλματος της πρόβλεψης. Όπως και προηγουμένως, σχεδιάστε ενδεικτικές οπτικοποιήσεις (true vs. predicted για κάποιον αισθητήρα) και σχολιάστε τα ευρήματά σας.

Περιεχόμενο παραδοτέου & προθεσμία παράδοσης: το παραδοτέο θα είναι ένα συμπιεσμένο αρχείο (zip) το οποίο αποτελείται από

- (i) μια σύντομη, αυτοτελή αναφορά **σε PDF** (μέγιστο μέγεθος: 15 σελίδες, διάστιχο: 1.5 γραμμές, μέγεθος γραμματοσειράς: 12 pt), και
- (ii) τα αρχεία κώδικα **μόνο** (όχι datasets, venv etc.) που αναπτύχθηκαν.

Το παραδοτέο θα υποβληθεί μέσω της σελίδας του μαθήματος στο e-class, με διορία παράδοσης την εκάστοτε ημερομηνία εξέτασης του μαθήματος στις εξεταστικές Ιαν. 2026, Ιουν. 2026 (για τους επί πτυχίω) και Σεπ. 2026. Στη συνέχεια, οι ομάδες ενδέχεται να κληθούν για μια σχετική παρουσίαση της εργασίας που ανέπτυξαν.

Προσοχή: Σε περίπτωση **λογοκλοπής** ή **αντιγραφής**, οι εμπλεκόμενες εργασίες μηδενίζονται. Ειδικά σε ό,τι αφορά στη **χρήση εργαλείων AI** (ChatGPT, κλπ.): η χρήση σχετικών εργαλείων δεν απαγορεύεται, όμως θα πρέπει να αναφέρετε ρητά σε ποια σημεία της εργασίας τα χρησιμοποιήσατε και για ποιο λόγο. Η μη αναφορά θεωρείται λογοκλοπή / αντιγραφή (βλ. παραπάνω).

Καλή επιτυχία!